ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO & POHE

BÀI TẬP LỚN MÔN KHOA HỌC DỮ LIỆU NHÓM 24

"ĐÁNH GIÁ CÁC YẾU TỐ LIÊN QUAN ĐẾN CHẤT LƯỢNG RƯỢU VANG ĐỎ"

Giảng viên: **TS. Trần Đức Minh**

Thành viên: **Đinh Diệu Hà Thu – 11242841**

Phạm Minh Châu – 11246830

Vũ Khánh Linh – 11243101

Đỗ Bảo Trân – 11241839

Hoàng Minh Trang – 11240126

Công cụ phân tích: Python, pandas, scipy, matplotlib

GitHub: https://github.com/jenniedinh-code/midterm_redWineQuality

Lớp chuyên ngành: **Đầu tư CLC 66A**

MỤC LỤC

TÓM TẮT 3
1. GIAI ĐOẠN 1 – THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU 3
1.1. Nguồn, cấu trúc và mục tiêu 3
1.2. Rà soát hiện trạng 4
2. GIAI ĐOẠN 2 – TIỀN XỬ LÝ VÀ LÀM SẠCH 4
2.1. Thao tác và kết quả 4
2.2. Phát hiện ngoại lệ bằng IQR 4
3. GIAI ĐOẠN 3 – PHÂN TÍCH, TRỰC QUAN HÓA VÀ KIỂM ĐỊNH 6
3.1. Phân bố biến kết quả 6
3.2. Nồng độ cồn và chất lượng 6
3.3. Tương quan giữa các đặc trưng 7
3.4. Axit bay hơi và so sánh hai nhóm chất lượng 7
3.5. Tổng hợp giả thuyết 8
4. GIAI ĐOẠN 4 – ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ 8
4.1. Phát hiện nổi bật 8
4.2. Khuyến nghị ứng dụng 9
4.3. Giới hạn và hướng mở rộng 9

DANH MỤC BẢNG VÀ HÌNH

Bảng 1. Cấu trúc trường dữ liệu 3
Bảng 2. Rà soát hiện trạng 4
Bảng 3. Ngoại lệ theo quy tắc IQR 5
Bảng 4. So sánh hai nhóm chất lượng bằng kiểm đụnh Mann-Whitney U 8
Bảng 5. Kết quả kiểm đụnh giả thuyết, mức ý nghĩa 0,05 8

Hình 1. Số lượng ngoại lệ IQR theo từng biến sau khi bỏ trùng 5
Hình 2. Số quan sát theo từng điểm quality 6
Hình 3. Histogram của alcohol và biểu đồ phân tán alcohol - quality 6
Hình 4. Ma trận tương quan Pearson giữa các biến hoá lý và điểm quality 7
Hình 5. Boxplot volatile acidity theo quality và giá trị trung bình theo nhóm chất lượng 7

TÓM TẮT

Tập dữ liệu gốc có 1.599 mẫu và 12 trường, gồm 11 đặc trưng hóa lý và 1 điểm chất lượng. Quy trình loại 240 hàng trùng hoàn toàn, giữ lại 1.359 mẫu; không phát hiện dữ liệu thiếu. Chất lượng trung bình là 5,62, trung vị là 6, thang điểm quan sát từ 3 đến 8.

Hai giả thuyết nghiên cứu đều được ủng hộ: alcohol và quality có tương quan Spearman dương với $\rho = 0{,}4880$; volatile acidity và quality có tương quan âm với $\rho = -0{,}3874$; giá trị p nhỏ hơn 0,001 cho cả hai. Đây là quan hệ thống kê, không chứng minh tác động nhân quả.

1. GIAI ĐOẠN 1 – THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU

1.1. Nguồn, cấu trúc và mục tiêu

Bộ dữ liệu có nguồn gốc từ nghiên cứu "Wine Quality" của Cortez và cộng sự, công bố năm 2009, được phát hành công khai trên UCI Machine Learning Repository và Kaggle. Phân tích này đọc trực tiếp file winequality-red.csv nên không phụ thuộc vào kết nối mạng hay tài khoản bên thứ ba. File CSV chứa duy nhất một bảng; vì vậy không có phép nối bảng, khóa chính, khóa ngoại hay kiểm tra toàn vẹn liên bảng.

Mục tiêu của báo cáo là mô tả chất lượng rượu vang đỏ, kiểm tra mối liên hệ giữa các chỉ số hóa lý với điểm quality, so sánh hai nhóm điểm nhỏ hơn 6 và từ 6 trở lên; từ đó đưa ra gợi ý kiểm soát chất lượng. Bài toán hiện tại là phân tích khám phá và kiểm định, chưa xây dựng mô hình dự báo.

Bảng 1. Cấu trúc trường dữ liệu

Nhóm trường	Tên trường	Kiểu dữ liệu
Đặc trưng hóa lý	fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide	float64
Đặc trưng hóa lý	total sulfur dioxide, density, pH, sulphates, alcohol	float64
Biến kết quả	quality	int64

Đơn vị được hiểu theo định nghĩa thông dụng của bộ Wine Quality: alcohol tính theo phần trăm thể tích; volatile acidity và citric acid tính theo g/L; sulphates tính theo g/L hoặc theo chỉ số của tài liệu gốc; các trường còn lại là phép đo hóa lý. Cần đối chiếu đơn vị với tài liệu dữ liệu gốc trước khi thiết lập ngưỡng vận hành.

1.2. Rà soát hiện trạng

Bảng 2. Rà soát hiện trạng

Chỉ tiêu kiểm tra	Kết quả	Nhận định
Quan sát / số cột	1.599 / 12	Đủ các trường mong đợi
Kiểu dữ liệu	11 biến đầu số thực; quality số nguyên	Không có trường chuỗi cần mã hóa
Giá trị thiếu	0 ô, tương đương 0,00%	Không cần điền thiếu
Hàng trùng hoàn toàn	240 hàng, tương đương 15,01%	Có trùng lặp theo toàn bộ 12 cột
Kiểm tra nối file	Không áp dụng	Chỉ có một file CSV

Cần lưu ý về dữ liệu trùng: bộ dữ liệu không có mã định danh từng chai. Những mẫu trùng toàn bộ chỉ số có thể là phép đo giống nhau ở các chai khác nhau; việc loại trùng là một quyết định phân tích cần xem xét lại nếu có thông tin định danh bổ sung.

2. GIAI ĐOẠN 2 – TIỀN XỬ LÝ VÀ LÀM SẠCH

2.1. Thao tác và kết quả

Bước 1: kiểm tra định dạng CSV và kiểu số. Bước 2: xác định 240 dòng trùng hoàn toàn bằng hàm duplicated() và loại bằng hàm drop_duplicates(), số dòng giảm từ 1.599 xuống 1.359. Bước 3: kiểm tra hàm isnull() trên toàn bộ cột, kết quả là 0 giá trị thiếu trước và sau xử lý. Bước 4: xây dựng cột quality_group chỉ phục vụ so sánh, không thay thế điểm quality.

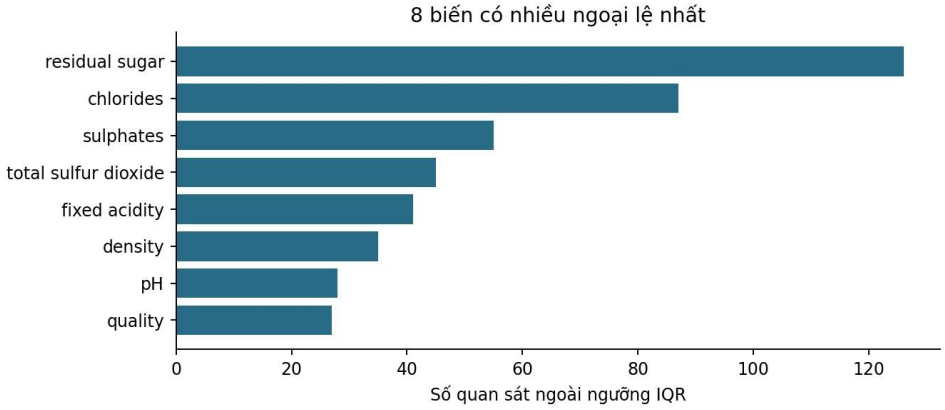
Quy trình có dự phòng điền thiếu bằng trung vị cho biến số, nhưng bước này không cần thực hiện vì dữ liệu không thiếu. Lý do chọn trung vị nếu xuất hiện giá trị thiếu là vì trung vị ít bị kéo lệch bởi các giá trị cực đoan hơn trung bình. Không có mã hóa biến phân loại ở đầu vào vì tất cả 12 trường ban đầu đều là số; không chuẩn hóa thang đo vì các kiểm định Spearman và Mann–Whitney dựa trên thứ hạng, còn biểu đồ được trình bày trên thang đo gốc để dễ diễn giải.

2.2. Phát hiện ngoại lệ bằng IQR

Với mỗi biến số, khoảng tứ phân vị được tính bằng IQR = Q3 − Q1; quan sát nằm ngoài khoảng từ Q1 − 1,5 × IQR đến Q3 + 1,5 × IQR được đánh dấu là ngoại lệ. Mỗi biến được xét riêng; một dòng có thể là ngoại lệ ở nhiều biến, vì thế không cộng số ngoại lệ giữa các cột.

Bảng 3. Ngoại lệ theo quy tắc IQR (sau khi bỏ trùng, n = 1.359)

Biến	Ngoại lệ	Tỷ lệ	Cận dưới – cận trên
residual sugar	126	9,27%	0,85 – 3,65
chlorides	87	6,40%	0,04 – 0,12
sulphates	55	4,05%	0,28 – 1,00
total sulfur dioxide	45	3,31%	−39,50 – 124,50
fixed acidity	41	3,02%	3,95 – 12,35
density	35	2,58%	0,99 – 1,00
pH	28	2,06%	2,92 – 3,68
quality	27	1,99%	3,50 – 7,50

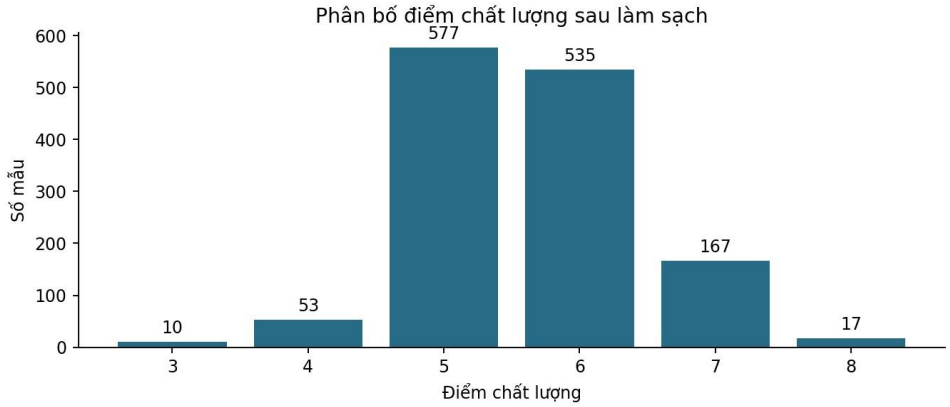


Hình 1. Số lượng ngoại lệ IQR theo từng biến sau khi bỏ trùng

Số ngoại lệ khác nhau đáng kể giữa các biến, cho thấy phân phối dữ liệu không hoàn toàn đối xứng. Phân tích chỉ phát hiện và trực quan hóa, không xóa ngoại lệ. Việc giữ nguyên là hợp lý ở bước khám phá vì giá trị cực đoan có thể là mẫu hóa lý thật; khi triển khai cần đối chiếu giới hạn đo, quy trình phòng thí nghiệm và các lô sản xuất.

3. GIAI ĐOẠN 3 – PHÂN TÍCH, TRỰC QUAN HÓA VÀ KIỂM ĐỊNH

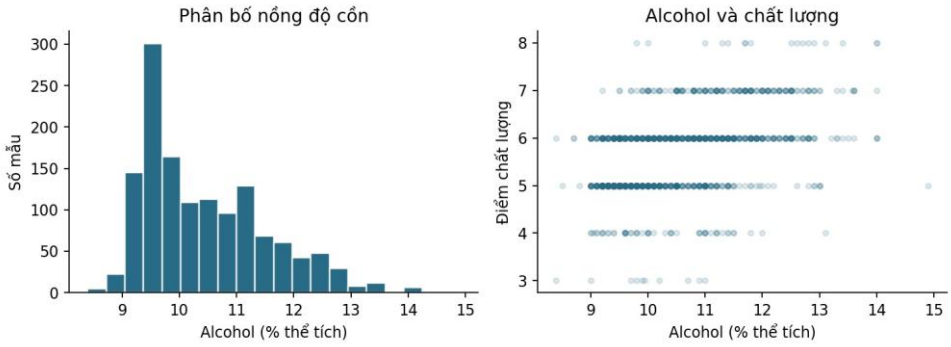
3.1. Phân bố biến kết quả



Hình 2. Số quan sát theo từng điểm quality

Các mức điểm xuất hiện như sau: mức 3 có 10 mẫu, chiếm 0,7%; mức 4 có 53 mẫu, chiếm 3,9%; mức 5 có 577 mẫu, chiếm 42,5%; mức 6 có 535 mẫu, chiếm 39,4%; mức 7 có 167 mẫu, chiếm 12,3%; mức 8 có 17 mẫu, chiếm 1,3%. Điểm tập trung chủ yếu ở mức 5 và 6; do đó nếu chỉ dùng độ chính xác tổng thể để đánh giá một mô hình phân loại trong tương lai thì có thể làm lu mờ khả năng nhận diện các mức điểm hiếm.

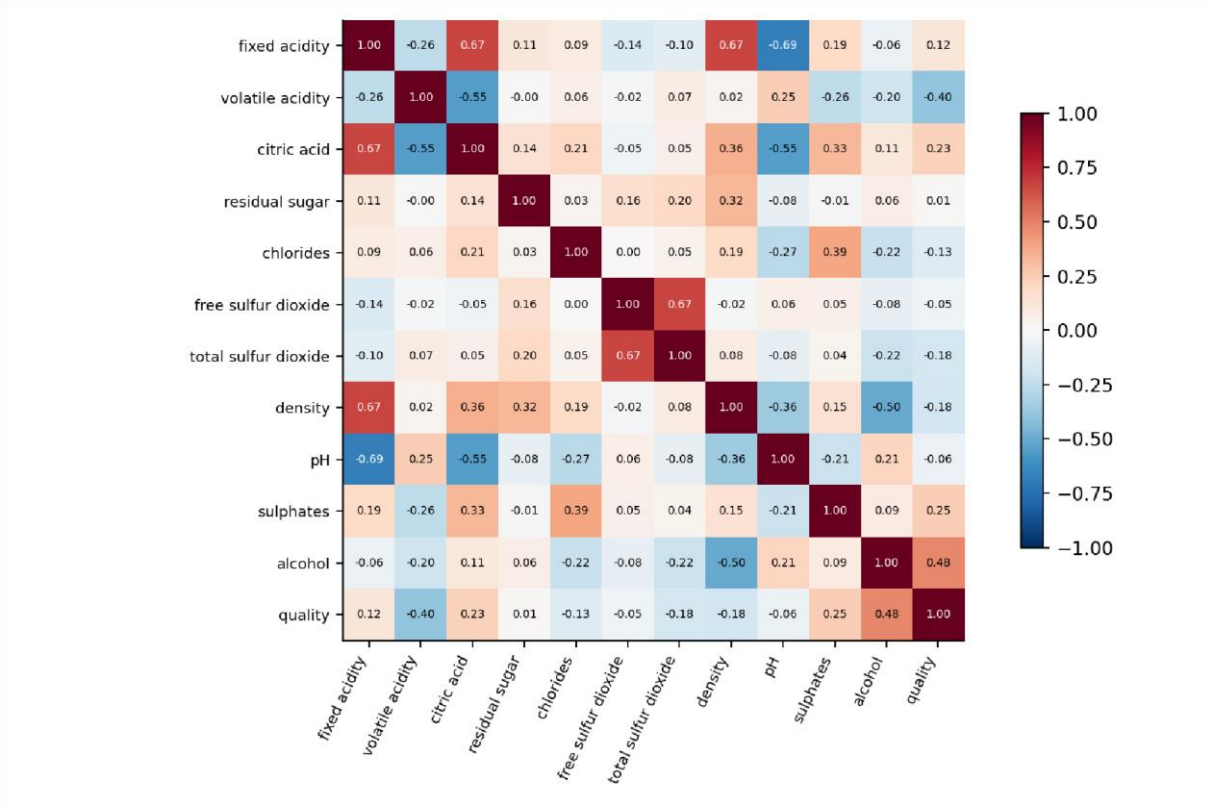
3.2. Nồng độ cồn và chất lượng



Hình 3. Histogram của alcohol và biểu đồ phân tán alcohol - quality

Biểu đồ histogram giúp quan sát dải giá trị và hình dạng phân bố của alcohol, còn biểu đồ phân tán biểu thị điểm chất lượng rời rạc theo alcohol. Kiểm định Spearman cho kết quả $\rho = 0{,}4880$ và $p = 3{,}24 \times 10^{-82}$. Giả thuyết H1 về tương quan dương được ủng hộ ở mức ý nghĩa 0,05; mức liên hệ tương đối rõ nhưng vẫn có sự chồng lấp chất lượng ở các mức cồn. Không thể suy ra rằng việc tự tăng nồng độ cồn sẽ nâng chất lượng.

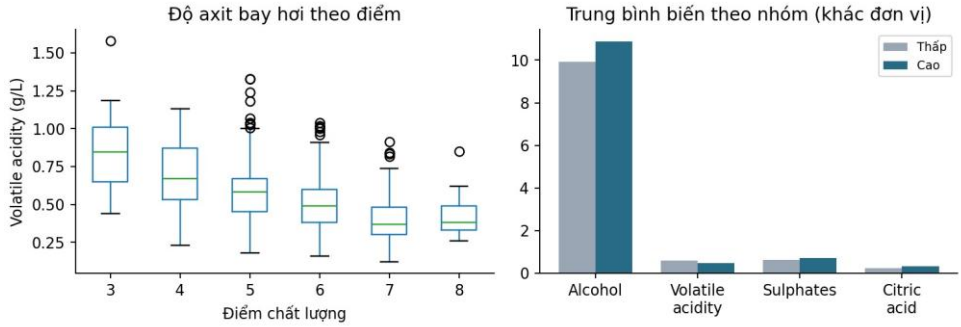
3.3. Tương quan giữa các đặc trưng



Hình 4. Ma trận tương quan Pearson giữa các biến hoá lý và điểm quality

Đối chiếu quality với bốn chỉ số được chọn cho kết quả: alcohol r = 0,480; volatile acidity r = −0,395; sulphates r = 0,249; citric acid r = 0,228. Ma trận sử dụng hệ số Pearson để mô tả tương quan tuyến tính, trong khi kiểm định giả thuyết dùng Spearman phù hợp với quality mang tính thứ bậc. Những ô tương quan giữa các biến đầu vào cũng gợi ý khả năng đồng biến, nên không đọc mỗi hệ số như một tác động độc lập.

3.4. Axit bay hơi và so sánh hai nhóm chất lượng



Hình 5. Boxplot volatile acidity theo quality và giá trị trung bình theo nhóm chất lượng

Kiểm định Spearman cho volatile acidity và quality cho kết quả ρ = −0,3874 và p = 6,54 × 10^{-50}; giả thuyết H2 về tương quan âm được ủng hộ. Boxplot biểu diễn vị trí trung vị, độ phân

tán và ngoại lệ theo từng điểm quality, giúp nhìn rõ độ chồng lấp giữa các mức điểm. Nhóm chất lượng cao, tức quality từ 6 trở lên, có 719 mẫu và chiếm 52,9%; nhóm thấp có 640 mẫu và chiếm 47,1%.

Bảng 4. So sánh hai nhóm chất lượng bằng kiểm đụnh Mann-Whitney U

Biến	TB nhóm thấp	TB nhóm cao	Giá trị p
alcohol	9,9208	10,8876	$1{,}78 \times 10^{-64}$
volatile acidity	0,5929	0,4730	$4{,}23 \times 10^{-35}$
sulphates	0,6205	0,6927	$4{,}46 \times 10^{-35}$
citric acid	0,2375	0,3033	$5{,}54 \times 10^{-10}$

Cả bốn biến được so sánh đều có giá trị p nhỏ hơn 0,05 theo kiểm định Mann– Whitney U hai phía. Điều này cho thấy có sự khác biệt về phân bố giữa hai nhóm, không đồng nghĩa là chênh lệch trung bình được kiểm định trực tiếp. Biểu đồ cột đặt các biến khác đơn vị cạnh nhau chỉ nên dùng để so sánh cùng một biến giữa hai nhóm, không so chiều cao giữa các biến khác nhau.

3.5. Tổng hợp giả thuyết

Bảng 5. Kết quả kiểm đụnh giả thuyết, mức ý nghĩa 0,05

Giả thuyết	Hệ số Spearman	Giá trị p	Kết luận
H1: Alcohol tăng thì quality tăng	0,4880	$3{,}24 \times 10^{-82}$	Ủng hộ
H2: Volatile acidity tăng thì quality giảm	−0,3874	$6{,}54 \times 10^{-50}$	Ủng hộ

Mức ý nghĩa được chọn là 0,05. Giá trị p hiển thị dưới dạng 0,00000 chỉ là kết quả làm tròn, không được hiểu là p đúng bằng 0. Các kiểm định này chưa điều chỉnh cho nhiều phép thử hoặc biến gây nhiễu.

4. GIAI ĐOẠN 4 – ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Phát hiện nổi bật

Dữ liệu sạch về thiếu giá trị nhưng có lượng trùng hoàn toàn đáng chú ý. Chất lượng tập trung chủ yếu ở điểm trung bình. Nồng độ cồn có quan hệ đồng biến với điểm chất lượng, còn axit bay hơi có quan hệ nghịch biến. Bốn đặc trưng được chọn để so sánh giữa hai nhóm đều có khác biệt thống kê, song kết quả hiện tại mang tính mô tả và quan sát.

4.2. Khuyến nghị ứng dụng

- Ưu tiên theo dõi alcohol và volatile acidity trong kiểm soát chất lượng: thiết lập biểu đồ theo lô, theo ca và theo thời điểm lên men; đánh giá xu hướng thay vì đặt ngưỡng cứng từ tương quan.
- Theo dõi bổ sung sulphates và citric acid cùng các chỉ số hóa lý còn lại để tránh tối ưu một biến đơn lẻ.
- Xây dựng bảng theo dõi có phân bố quality, tỷ lệ nhóm từ 6 điểm trở lên, ngoại lệ đo lường và độ ổn định các thông số theo lô.
- Trước khi điều chỉnh công thức hoặc quy trình, cần thẩm định bằng thử nghiệm có kiểm soát và đánh giá cảm quan độc lập.

4.3. Giới hạn và hướng mở rộng

Về giới hạn, bộ dữ liệu không có mã mẫu, thời gian, nhà sản xuất, lô rượu, điều kiện bảo quản hoặc dữ liệu chi phí; chất lượng là điểm cảm quan rời rạc; dữ liệu quan sát không suy luận được quan hệ nhân quả. Việc bỏ trùng có thể loại cả các phép đo trùng hợp thực sự. Các phép thử chưa kiểm soát biến gây nhiễu và chưa hiệu chỉnh đa kiểm định; nhóm từ 6 điểm trở lên là quy ước phân tích của báo cáo này, không phải chuẩn pháp quy.

Về hướng mở rộng, cần xác minh nguồn gốc và đơn vị của từng trường; bổ sung mã lô, dữ liệu thời gian, thông tin các đánh giá viên và mẫu theo đợt; phân tích độ nhạy trong hai trường hợp có và không loại trùng; xây dựng mô hình hồi quy thứ bậc hoặc phân loại có xác thực chéo và tập kiểm tra độc lập; dùng SHAP hoặc partial dependence để diễn giải dự báo nhưng vẫn phân biệt liên hệ và nhân quả; thực hiện kiểm định với hiệu chỉnh đa so sánh khi cần thiết.